

МИНОБРНАУКИ РОССИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«ВОРОНЕЖСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(ФГБОУ ВО «ВГУ»)

Факультет прикладной математики, информатики и механики

Кафедра вычислительной математики и информационных
прикладных технологий

Направление 01.04.02 Прикладная математика и информатика

Отчёт

по производственной практике (научно-исследовательская работа)

Тема	Разработка аппаратной реализации 2D графического ускорителя
Отчетный семестр	4

Обучающийся	2 курс, 11 группа, Старухин Д.М.
Руководитель от кафедры	к.ф.-м.н., доц. Медведева О.А.

Воронеж 2026

Содержание

Введение	3
Постановка задачи	4
Актуальность поставленной задачи	5
1. Классификация параллельных вычислительных моделей (SIMT vs SIMD, MIMD)	6
Литература	10

Введение

В этой работе будет представлена аппаратная архитектура реализации ядра для графических ускорителей. Также, в этой работе будут рассмотрены другие архитектуры графического ядра у ведущих компаний в разработке графических ускорителей. С учётом уже существующих архитектур графических ядер, в работе будет представлена собственная архитектура графического ядра.

Постановка задачи

Компанией АО «ПКК» Миландр была поставлена задача разработать аппаратную реализацию 2D графического ускорителя. Перед началом аппаратной разработки необходимо описать архитектуру, которой должен соответствовать сложно-функциональный (СФ) блок.

При разработке архитектуры учитываются проделанные ранее обзор и анализ 2D графических ускорителей [1]. Разработка ведется с учётом предложенной ранее [2] архитектурой графического ускорителя.

Перед тем как разработать аппаратную реализацию 2D графического ускорителя, необходимо и важно разобраться в предназначении и структуре различных компонентов IP-блока. Одним из таких компонентов, является графическое ядро.

Графическое ядро имеет довольно сложную архитектуру, которое состоит из элементов, которые должны корректно соответствовать друг другу. Поэтому, перед разработкой графического ядра, нужно разработать его архитектуру, с учётом разработок графических ядер других кампаний.

Актуальность поставленной задачи

В современном мире, в условиях развития нейросетей и импортозамещения, создание собственных специализированных графических и вычислительных архитектур является довольно важной задачей.

Нейросети все больше вовлекаются во многие аспекты, начиная от развлекательной индустрии, заканчивая научными исследованиями. Искусственный интеллект образовал огромный спрос видеокарт, с помощью которых можно собрать вычислительный сервер, на которых, можно развернуть нейросеть для решения различных задач. Видеокарта состоит из большого количества элементов, одним из которых является графический процессор [3]. графический процессор обладает большим количеством ядер, которые выполняют огромный объем вычислений с плавающей точкой.

Помимо искусственного интеллекта, графические ядра также могут использоваться в вычислениях рендеринга графики, обработки видео или фото, а также в различных научных вычислениях, где требуется рассчитывать тысячи параллельных математических вычислений.

Разработка архитектуры графического ядра позволит снизить зависимость от зарубежных архитектур, таких, как AMD, ARM Mali и Nvidia. Благодаря разработке IP-блока, можно достичь создания доверенных систем, которые не будут содержать в себе наличия аппаратных «закладок» и недокументированных функций в критически важной инфраструктуре.

1. Классификация параллельных вычислительных моделей (SIMT vs SIMD, MIMD).

Современные графические ускорители выполняют большое количество мелких задач одновременно. В отличие от центрального процессора (CPU), который предназначен для последовательного выполнения комплексных задач, графические ускорители спроектированы так, чтобы те выполняли множество небольших и независимых вычислений, таких как, к примеру отрисовки пикселей или обучение нейросетей. Одну такую мелкую задачу может выполнять специализированный блок, который называют ядром графического ускорителя. В современных видеокартах (GPU), количество ядер может скалироваться от нескольких тысяч до нескольких десятков тысяч.

Различие количества ядер у CPU и GPU является в том, что центральный процессор выполняет большой спектр различных, сложных и разнообразных задач, последовательно, в то время, как ядро GPU является узкоспециализированным ядром, который может выполнять лишь определенный список задач, которые приходят на обработку. Объем задач у CPU и GPU сильно отличается, ядро CPU обладает большим размером кеша, чем ядро GPU. Чем меньше логики у аппаратного блока и чем меньше для него создано памяти для хранения временных и локальных данных и инструкций, тем меньше размер аппаратного блока. Следовательно размер одного ядра CPU намного больше ядра GPU.

В отличие от ядер CPU, ядра GPU выполняют параллельно похожие операции над данными. В компьютерной графике, мультимедиа, криптографии и машинном обучении часто происходит ситуация, когда нужно работать с большим объемом данных, которым требуется одна и та же обработка. Взять в пример вычисление какой-либо картинки на экране монитора - на сегодняшний день, разрешения экранов достигают более 2 миллионных пикселей, что представляет собой уже огромный пласт работы, который необходимо обрабатывать чуть ли не за десятки миллисекунд. Поэтому, графические ускорители обладают маленькими, но многочисленными ядрами, тем самым позволяя работать с кучей данных, требующих одних и тех же инструкций за очень короткое время.

В разработке графических ускорителей принимают архитектурную классификацию параллелизма в потоках команд и данных SIMD, которая является одной из

основных возможных архитектур параллелизма, основанных на таксономии Флинна. Среди основных классов наблюдаются следующие виды:

- ОКОД (SISD - single instruction, single data) - одиночный поток команд, одиночный поток данных;
- ОКМД (SIMD - single instruction, multiply data) - одиночный поток команд, множественный поток данных;
- МКОД (MISD - multiply instruction, single data) - множественный поток команд, одиночный поток данных;
- МКМД (MIMD - multiply instruction, multiply data) - множественный поток команд, множественный поток данных [4].

Все классы архитектур по Флинну представлены на рис. 1:




Рис. 1 — Все виды архитектур по таксономии Флинна

Примером архитектуры SISD является традиционный компьютер фон-Неймановской архитектуры с одним процессором, который выполняет последовательно одну инструкцию за другой, работая с одним потоком данных. SISD не является параллельной [5]. Основывать графический процессор на архитектуре SISD приведёт к слабой производительности, так как архитектура SISD вызывает ограничение скорости из-за своей природы. Первые процессоры основывались на этой архитектуре.

Архитектура SIMD позволяет обеспечить параллелизм на уровне данных, позволяя работать с большим количеством информации, над которой требуется работа лишь одной конкретной инструкции. [6] Технология SIMD не только улучшает производительность вычислительных систем, но и уменьшает площадь, ибо количество необходимых шин, для того чтобы связать аппаратные блоки существенно уменьшается. На основе этой архитектуры была разработана архитектура SIMT (Single Instruction Multiple Threads) - одна инструкция, множество потоков.

Архитектура MISD основана на том, что множество инструкций будет работать с одиночным потоком данных. Это может быть полезно в различных системах с отказоустойчивостью: в космонавтике или авионике. Множество процессоров работают над одним и тем же потоком данных. [7] В нейросетях и графике нет необходимости различными инструкциями выстраиваться в очередь для обработки одного потока данных. При такой архитектуре графическое ядро будет обладать большими задержками, что противоречит цели в создании производительной архитектуры графического ускорителя.

MIMD архитектура является распространенной архитектурой в компьютерах с несколькими процессорами. Благодаря такой архитектуре, можно обеспечить эффективное использование аппаратных ресурсов. При этом, ядра, которые будут использовать архитектуру MIMD будут сложными, т.к. на каждый поток команд и инструкций необходимо разработать блок выборки и декодирования команд, что увеличит место на кристалле, а также увеличит объем потребляемой энергии. Из-за такой архитектуры также необходимо разработать сложную систему планирования, потому что в MIMD могут возникнуть проблемы с взаимной блокировкой и состязанием за обладанием ресурсами. Это связано с тем, что потоки, пытаясь получить доступ к ресурсам, могут встретиться непредсказуемым способом на одном и том же ресурсе и такую проблему необходимо будет решать отдельными компонентами в архитектуре, которые также будут занимать место и энергию на кристалле [8].

Среди всех архитектур для разработки графического ядра явно подходит архитектура SIMD. На её основе будет разрабатываться архитектура графического ядра.

Литература

- [1] И.А. Дудкин, Д.М. Старухин, и В.В. Черкасов, «Обзор и анализ 2D графических ускорителей».
- [2] И.А. Дудкин, Д.М. Старухин, и В.В. Черкасов, «Разработка архитектуры аппаратной реализации 2D графического ускорителя».
- [3] «Видеокарта». [Онлайн]. Доступно на: <https://ru.wikipedia.org/wiki/%D0%92%D0%B8%D0%B4%D0%B5%D0%BE%D0%BA%D0%B0%D1%80%D1%82%D0%B0>
- [4] «Таксономия Флинна». [Онлайн]. Доступно на: https://en.wikipedia.org/wiki/Flynn%27s_taxonomy
- [5] «SISD». [Онлайн]. Доступно на: <https://ru.wikipedia.org/wiki/SISD>
- [6] «SIMD». [Онлайн]. Доступно на: <https://ru.wikipedia.org/wiki/SIMD>
- [7] «MISD». [Онлайн]. Доступно на: <https://ru.wikipedia.org/wiki/MISD>
- [8] «MIMD». [Онлайн]. Доступно на: <https://ru.wikipedia.org/wiki/MIMD>